

# Bewegingsherkenning met een smartphone

**Arne De Brabandere**

arne.debrabandere@student.kuleuven.be

**Menno Keustermans**

menno.keustermans@student.kuleuven.be

## Abstract

Bewegingsherkenning is een belangrijke doelstelling van "context aware computing". Het gebruik van accelerometer gegevens geleverd door een smartphone zorgt ervoor dat een gegevensset snel geleverd kunnen worden. In het eerste deel van ons onderzoek hebben we gezocht naar een model om afzonderlijke activiteiten te herkennen. Het nauwkeurigste model werd gevonden met de classificatiemethode: RandomForest met 93%. Vervolgens hebben we dit model gebruikt om een sequentie van verschillende bewegingen te evalueren. Het algoritme dat we hiervoor ontwikkeld hebben, knipt de sequentie in opeenvolgende tijdsvensters van  $x$  aantal seconden die ook met een bepaald percentage kunnen overlappen. Uit experimenten bleek dat hiervoor een tijdsvenstergrootte van vier seconden met overlapping van 75% het nauwkeurigst bleek te werken.

## 1 Introductie

### Gerelateerd werk

## 2 Afzonderlijke activiteiten

Het eerste probleem is om van een gegeven reeks samples van de accelerometer en gyroscoop van een smartphone de activiteit van een persoon te bepalen. We veronderstellen hier dat telkens één afzonderlijke activiteit gemeten wordt.

We willen tien verschillende activiteiten kunnen herkennen:

- wandelen,
- lopen,
- fietsen,
- een trap opwandelen,
- een trap afwandelen,
- springen,
- niets doen (zitten, liggen, staan),
- een lift naar boven nemen,
- een lift naar beneden nemen,

- tanden poetsen.

In bovenstaande lijst hebben we tanden poetsen als moeilijke activiteit toegevoegd. De beweging lijkt sterk op niets doen en zal waarschijnlijk minder goed te herkennen zijn. Ook voor lift naar boven en trap opwandelen bestaan er gelijkaardige bewegingen, respectievelijk lift naar beneden en trap afwandelen.

Het proces om een afzonderlijke activiteiten te herkennen verloopt in drie stappen. Ten eerste moeten er gegevens verzameld worden. Als tweede stap worden er features berekend op de verzamelde gegevens. Deze zijn nodig om tenslotte modellen te leren met behulp van classificatiemethodes. Als criterium om de verschillende modellen te vergelijken, gebruiken we de accuraatheid als percentage van het aantal juiste geclassificeerde samples ten opzichte van het totaal aantal samples met behulp van cross-validatie.

### 2.1 Gegevensverzameling

Alle gegevens werd opgemeten door MotionTracker tool. Dit is een Android-applicatie die de versnelling en rotatie (respectievelijk gemeten door de accelerometer en gyroscoop van de smartphone) aan 50 Hertz. Als uitvoer geeft de applicatie een .log-bestand met de gemeten versnellingen (in de  $x$ -as,  $y$ -as en  $z$ -as met de  $z$ -as evenwijdig met de gravitatie) en rotaties (in quaternion notatie) met bijhorende timestamps.

Voor elke meting werd de applicatie gestart alvorens de smartphone in de broekzak gestopt werd en gestopt na het uithalen. Waardoor er bij het begin en einde van elke meting altijd enkele seconden niet-activiteit bevat. Om zo het fout labelen te vermijden, werd na elke meting een stuk van de start en het einde van het .log-bestand weggeknipt. Zodat elke meting exact één activiteit bevat van vier á twintig seconden.

We hebben voor elke activiteit 22 metingen verzameld, opgemeten door twee verschillende personen. Om voldoende variatie te hebben, gebeurden de metingen op verschillende dagen. Ook hebben we ervoor gezorgd dat we niet telkens dezelfde broek droegen, aangezien de gemeten versnelling kan variëren in verschillende broekzakken. Na elke meting werd het uitgevoerde .log-bestand geknipt en gelabeld met de juiste activiteit.

### 2.2 Gegevensverwerking: features berekenen

Voor we classificatiemethodes kunnen gebruiken, moeten we eerst features berekenen. Dit zijn parameters die we uit de

samples van de accelerometer en gyroscoop kunnen halen. Om de verschillende features te berekenen, maakten we gebruik van MotionFingerPrint.jar tool

MotionFingerPrint berekent in totaal 134 features verdeeld onder vier soorten:

- *Statistische features*: dit zijn gemiddelde, standaardafwijking van zowel z- als xy-versnellingen en vermogen. En correlatie tussen z- en xy-versnelling.
- *Fourier-transformatie*: deze worden berekend in het frequentie domein van de metingen, zoals amplitudes volgens de verschillende assen.
- *Wavelet-transformatie*:
- *Hidden Markov models*: log-likelihood voor het model van elke activiteit

Het resultaat van de features berekening geeft een voor elke sample een set van parameters. Elke set vormt een instantie van de training set om een model te leren.

### Feature selectie

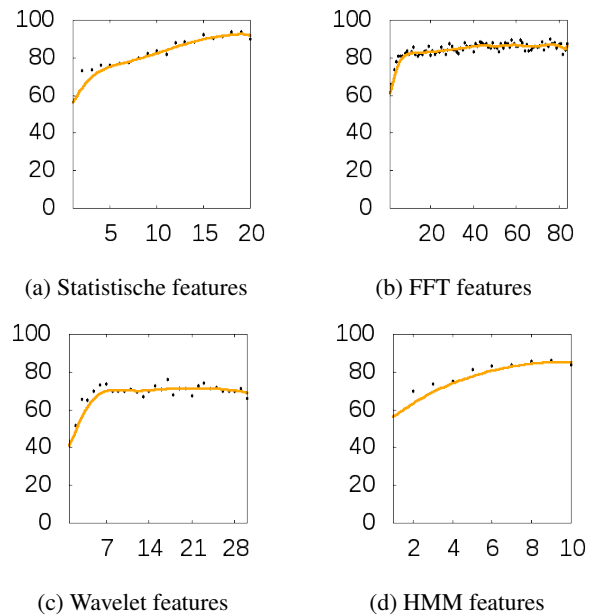
Tussen de verschillende soorten features is er verschil in berekeningstijd en hoeveelheid informatie. Zo kunnen statistische features in het algemeen tegen een lagere kost berekend worden ten op zichte van fourier transformatie features. In sommige toepassingen kan het daarom interessant zijn om slechts een deel van het totaal aantal features te berekenen en juist degene die het meeste informatie bevatten.

Met behulp van feature selectie hebben we onderzocht hoeveel features van het totaal aantal features van elke soort nodig zijn om een redelijke accuraatheid te behalen. Om de features met het meeste informatie te vinden, maakten we gebruik van weka's: *InfoGainAttributeEval* klasse. Deze klasse evalueert de waarde van elke features met behulp van information gain. Hierbij werd er steeds de entropie waarde berekend.

Vervolgens om de geselecteerde features te evalueren maakten we gebruik van dubbele cross-validatie. Bij de eerste cross-validatie (10-fold) werd de gegevensset verdeeld in een training- en testset. Daarna gebruikten we de gegeneerde training-set om de beste features te selecteren met het proces dat hierboven werd beschreven gebruik makend van de tweede cross-validatie (2-fold). Met de geselecteerde features werd een model opgesteld met behulp van de randomForest classificatiemethode. En dit model werd uiteindelijk getest om de testset die bij de eerste cross-validatie gemaakt werd.

In figuur X worden de resultaten voor de verschillende soorten features getoond. We zien dat we met enkel de statistische features al een accuraatheid van 90% behalen. Zelfs met de helft kan het model al vrij zeker de juiste activiteit voorspellen. We stellen vast dat van het grote aantal fourier transformatie features slechts een tiental nodig zijn om een nauwkeurigheid van 80% te bekomen. In het algemeen kunnen we kunnen concluderen dat wavelet transformatie functie minder goed werken (slechts 70% accuraatheid). Tenslotte in de laatste grafiek merken we op dat de Hidden Markov Models enkel degelijk werken als alle features gebruikt worden.

Voor de rest van het onderzoek werd gebruik gemaakt van de volledige set features.




Figuur 1: Resultaten van het feature selectie experiment. Op de x-as wordt steeds het aantal features van de soort features geplott en op de y-as de accuraatheid in procenten.

### 2.3 Classificatiemethodes

We gebruiken classificatiemethodes om een model te zoeken om afzonderlijke activiteiten te herkennen. We vergelijken enkele veel voorkomende methodes: beslissingsbomen, Random Forest, k-Nearest Neighbours, Naive Bayes en Support Vector Machines. De methodes leren telkens een model uit de instanties met de hierboven beschreven features voor de verschillende activiteiten. Hieronder wordt kort de werking van de vernoemde methodes beschreven:

- *Beslissingsbomen* zijn bomen waarvan de interne knopen features voorstellen en de bladknopen één (of meerdere) labels bevatten. Een tak in de boom stelt een test voor op de feature van de knoop waaruit de tak vertrekt. Om een nieuwe instantie te classificeren worden de juiste takken gevolgd tot in een bepaalde bladknoop. De instantie wordt dan geclassificeerd als het label in die bladknoop.
- *Random Forests* zijn combinaties van beslissingsbomen met een willekeurig deel van de trainingset en een willekeurig deel van de features. Bij de classificatie van een nieuwe instantie 'stemt' elke boom op een label. De instantie krijgt vervolgens het label met de meeste stemmen.
- *k-Nearest Neighbours* classificeert nieuwe instanties door te zoeken naar de k dichtstbijzijnde instanties in de trainingset. Dit zijn de instanties waarvan de waarden voor de features het dichtst bij die van de te classificeren instantie ligt. Hieruit wordt het meest voorkomende label gekozen.
- *Naive Bayes* is een probabilistische classifier die gebruik maakt van voorwaardelijke kansen. De kans op



Figuur 2: Accuraatheid van classificatiemethodes

een label  $C$  met gegeven waarden voor de features  $\mathbf{F} = (F_1, \dots, F_n)$  wordt berekend als  $P(C|\mathbf{F}) = \frac{P(\mathbf{F}|C)P(C)}{P(\mathbf{F})}$  waarin  $P(\mathbf{F}|C)$ ,  $P(C)$  en  $P(\mathbf{F})$  uit de trainingset kunnen berekend worden. Bij het classificeren wordt het label met de grootste kans gekozen.

- *Support Vector Machines* beschouwt de features als een multidimensionale ruimte. De instanties zijn dan punten in de featureruimte. Bij het leren worden de instanties lineair van elkaar gescheiden door hypervlakken, zodat de instanties aan de ene kant van het vlak een ander label hebben dan die aan de andere kant. Wanneer de instanties niet lineair te scheiden zijn, worden ze getransformeerd met een *kernel functie*. We gebruiken hier LibSVM, waarbij binaire (één-tegen-één) classificatie gedaan wordt: elk hypervlak scheidt de instanties van 2 verschillende labels. Een nieuwe instantie wordt geclassificeerd door elke binaire classificatie als een stem voor een label te beschouwen. Het label met het grootste aantal stemmen wordt gekozen.

## 2.4 Experimenten en resultaten

Om de methodes te evalueren, maken we gebruik van de Weka Machine Learning Toolkit. Die bevat classifiers die de hierboven vermelde methodes implementeren. Voor beslissingsbomen maken we gebruik van de J48 classifier, een implementatie van het C4.5 algoritme. Verder gebruiken we IBk voor k-Nearest Neighbours en LibSVM voor Support Vector Machines.

De evaluatie gebeurt met 10-fold cross-validatie. Hierbij worden de instanties op 10 verschillende manieren opgesplitst zodat telkens 90% van de instanties als trainingset wordt gebruikt om een model uit te leren. Op de overige 10% wordt het model geëvalueerd. De accuraatheid van elke methode wordt dan berekend als het gemiddelde percentage van correct geclassificeerde instanties in de verschillende testsets.

In figuur 2 wordt de accuraatheid van de verschillende classificatiemethodes vergeleken. We zien dat Random Forest

de hoogste accuraatheid geeft voor de metingen. Ook J48 geeft een goede accuraatheid. De hogere accuraatheid van Random Forest ten opzichte van beslissingsbomen is te verklaren door het feit dat Random Forest minder kans op overfitting heeft. [Breiman, 2001] Naive Bayes lijkt ook goed te werken, terwijl met IBk en vooral LibSVM een lagere accuraatheid bereikt wordt. De accuraatheid van de methodes kan echter wel verbeterd worden door de parameters te optimaliseren.

Voor het model dat door Random Forest geleerd wordt, hebben we in figuur 3 een confusion-matrix geplot. Het valt op dat activiteiten met grote versnellingen – wandelen, lopen, fietsen en springen – goed te herkennen zijn. Alle metingen voor deze activiteiten worden immers correct geclassificeerd door het model. Niets doen, lift omhoog/omlaag en tanden poetsen hebben kleinere versnellingen dan de andere activiteiten. We zien dat 2 metingen van niets doen als tanden poetsen worden geclassificeerd. Ook lift omhoog en omlaag worden gemakkelijk met elkaar verward. Omwille van de kleine versnellingen zijn de verschillen tussen de activiteiten subtieler, wat een verklaring kan zijn waarom deze activiteiten moeilijker te herkennen zijn.

## 3 Sequenties van activiteiten

Bij het herkennen van afzonderlijke activiteiten bevat elke meting exact één activiteit. De classificatiemethodes die we hiervoor gebruiken zijn dus niet rechtstreeks toepasbaar op metingen waarin verschillende activiteiten na elkaar gebeuren. Daarom gaan we op zoek naar een methode om voor een sequentie van activiteiten te bepalen welke activiteiten daarin gedaan worden en wanneer.

### 3.1 Gegevensverzameling

Met behulp van de MotionTracker applicatie werd opnieuw de versnelling en rotatie gemeten, maar nu van meerdere activiteiten na elkaar. In totaal zijn vier sequenties van elk ongeveer drie minuten lang opgemeten: twee verschillende combinaties van activiteiten, telkens door twee personen opgemeten. De ene combinatie bevat de activiteiten wandelen, trap op en af, niets doen, lopen en springen. De andere bevat wandelen, trap op en af, niets doen en lift omhoog en omlaag. Omdat lift versnellingen moeilijk van elkaar te onderscheiden zijn door het model voor afzonderlijke activiteiten (zie sectie 2.4), is de tweede combinatie moeilijker te herkennen dan de eerste.


Om de metingen te evalueren, werd elke sequentie gelabeld met behulp van een .csv-bestand. Dit bestand bevat de start- en eindtijden van de verschillende activiteiten in de bijhorende meting. De delen die niet gelabeld werden, beschouwen we als ruis. Het gaat om periodes met activiteiten die niet tot de tien activiteiten behoren die we kunnen herkennen. De smartphone in de broekzak stoppen is hier een voorbeeld van.

### 3.2 Gegevensverwerking

Aangezien de modellen voor afzonderlijke activiteiten niet rechtstreeks kunnen toegepast worden op sequenties, moeten de sequenties geknipt worden in delen die wel één acti-

	Wandelen	Lopen	Fietsen	Trap op	Trap af	Springen	Niets doen	Lift omhoog	Lift omlaag	Tanden poetsen	geclassificeerd ← als
16											Wandelen
	16										Lopen
		16									Fietsen
			15	1							Trap op
				16							Trap af
					16						Springen
						14				2	Niets doen
								10	6		Lift omhoog
								1	15		Lift omlaag
										16	Tanden poetsen

Figuur 3: Confusion matrix voor Random Forest



Figuur 4: Tijdsvensters met 75% overlapping

viteit bevatten. We doen dit door de sequenties in tijdsvensters op te splitsen. De vensters hebben een lengte van enkele seconden en kunnen overlappen. We definiëren een overlapping als het percentage van de lengte van een tijdsvenster dat ook tot het eerst volgende tijdsvenster hoort. In figuur 4 wordt geïllustreerd wat bedoeld wordt met een overlapping van 75%.

### 3.3 Algoritme

### 3.4 Experimenten en resultaten

In figuur X worden de verschillende combinaties van de tijdvenster- en overlappingsgrootte getoond met de behaalde accuraatheid. Indien we de x-as volgen, dus er wordt een constante overlappingsgrootte gehouden. Zien we naarmate dat de tijdsvenstergrootte stijgt dat ook de accuraatheid stijgt. Er wordt een maximum gehaald rond de vier seconden, daarna daalt de accuraatheid terug. Bij het volgen van de y-as, dus een constante tijdsvenstergrootte. Kunnen we constateren dat hoe groter het overlappingspercentage, hoe nauwkeuriger er voorspellingen gemaakt kunnen worden.

Deze resultaten komen overeen met de hypothese die eerder gemaakt werd. De periodes van de meeste activiteiten duren enkele seconden lang. Bijvoorbeeld liftversnellingen duren meestal vier seconden. Hierdoor is te verklaren waarom dat grotere tijdsvenster een betere nauwkeurigheid opleveren. Zo zijn tijdsvenster van één of twee seconden niet genoeg om een hele periode van een activiteit te bevatten. Grotere tijdsvenster leveren een lagere accuraatheid op omdat de kans dat éénzelfde venster meerdere activiteiten bevat groter is. Daardoor is het moeilijker om de juiste activiteit te herkennen. De stijgende nauwkeurigheid voor toenemende overlappingsgrootte was ook te verwachten. Hoe groter de overlapping, hoe meer voorspellingen er gemaakt kunnen worden. Hierbij moet wel uiteindelijk een trade-off gemaakt worden. Meer voorspellingen maken, vraagt immers meer tijd.

Uit het vorige experiment kunnen we concluderen dat de optimale venstergrootte vier seconden is in combinatie met 75% overlappings. Deze waarden samen met 50% ruis cut-off leveren een nauwkeurigheid van

## 4 Conclusie

Het doel van dit onderzoek was om een model te vinden om afzonderlijke bewegingen te herkennen. En vervolgens dit model te gebruiken om een sequentie van verschillende activiteiten te evalueren.

In sectie 2 werden twee experimenten uitgevoerd in verband met afzonderlijke activiteiten. Het eerste experiment betreft de feature selectie. Hierbij werd geëxperimenteerd hoeveel features er nodig zijn om een voldoende nauwkeurig model te vinden. Het resultaat leverde op dat enkel statistische features een model opleveren met 90% nauwkeurigheid. We kunnen bij hetzelfde experiment ook concluderen dat van de tachtig fourier transformatie features slecht een tiental nodig zijn. Het tweede experiment diende om de verschillende classificatiemethodes te vergelijken met elkaar. We maakten gebruik van zes veel voorkomende machine learning technieken: beslissingsbomen, random forests, k-nearest neighbours, naive bayes en support vector machines. Van deze methodes kwam random forest als beste naar boven met een nauwkeurigheid van 93,75%.

In sectie 3 werden sequenties van activiteiten geëvalueerd. Hiervoor hebben we een algoritme ontwikkeld waarvan de pseudocode besproken werd in . Vervolgens hebben we onderzocht welke combinatie van waarden voor de parameters: tijdsvenstergrootte (in seconden) en overlappingsgrootte (in procenten) het nauwkeurigste werkt om sequenties te voorspellen met een constante ruis cut-off van 50%. Dit experi-

ment werd uitgebreid besproken in sectie 3.4. Uit dit experiment bleek dat optimale waarde voor de tijdsvenstergrootte vier seconden gebruik makend van 75% overlappings. Vervolgens werden deze waarden getest op sequenties met steeds 4 á 5 verschillende activiteiten van ongeveer 3 minuten lang. Met behulp van het RandomForest-model (dit is het model dat gevonden werd in sectie 2) werd er een gemiddelde nauwkeurigheid van 80% gevonden.

## 5 Verder werk

Ondanks dat er tijdens dit onderzoek een redelijk model werd gevonden, kan deze altijd verder uitgebreid worden.

### 5.1 Afzonderlijke activiteiten

Het model van de afzonderlijke activiteiten kan verbeterd worden door de gegevensverzameling te vergroten. Dit betekent dat er meer gegevens verzameld moeten worden door meerdere proefpersonen. Hierdoor kan er een algemener model berekend worden voor de verschillende afzonderlijke activiteiten waardoor het model nauwkeurigere voorspellingen kan doen bij de sequenties van activiteiten.

Bovendien kunnen er modellen gegenereerd worden voor nieuwe activiteiten. Het toevoegen van extra activiteiten zal zoals eerder vermeld ook meer gegevens vragen.

### 5.2 Sequentie van activiteiten

Het algoritme voor sequenties van activiteiten te evalueren, kan ook nog verder geoptimaliseerd worden. Zo zijn bepaalde overgangen van activiteiten totaal onmogelijk. Bijvoorbeeld het herkennen van fietsen na een liftversnelling is onwaarschijnlijk. Zulke overgangen kunnen gefilterd worden door het gebruik van hidden markov models. Vervolgens hebben wij tijdens het onderzoek gezien dat er soms enkele seconden als tanden poetsen herkend worden tijdens niets doen. Ook dit is onwaarschijnlijk en zou gefilterd kunnen worden met behulp van HMMs.

Tijdens het onderzoek werd geen rekening gehouden met de performantie (noch snelheid, noch geheugengebruik). Deze kan verder onderzocht en eventueel verbeterd worden.

Tenslotte is het nog mogelijk om het algoritme te implementeren in een smartphone-applicatie.

## 6 Dankwoord

Hierbij willen we graag Wannes Meert en Leander Schietgat bedanken. Eerst en vooral voor hun raad en ondersteuning. Ten tweede voor het ter beschikking stellen van de tools: MotionTracker en MotionFingerPrint.

## Referenties

[Breiman, 2001] Leo Breiman. Random Forests. *Machine Learning*, 45(1):5–32, Oktober 2001.